

RMOEA/D 求解双目标模糊柔性作业车间调度

——复现、评价口径纠正与组件有效性再评估

2026 年 9 月 19 日

摘要

Li 等 (2022) 提出的 RMOEA/D 用 Q-learning 同时驱动参数自适应 (Q-PAS) 与变邻域算子选择 (RVNS), 在双目标模糊柔性作业车间调度上报告了良好效果。本文在 Brandimarte Mk01-Mk10 上对该算法做了可复现的重实现, 并在统一评价口径下重新审计其每个组件。工作有三点。其一, **评价口径**: 我们指出文献与复现中普遍使用的“按参与比较的前沿取归一化边界”(下称盒口径) 有两个不可修复的缺陷——边界随实例集与臂集漂移, 且系统性放大效应量; 实测同一批数据下按臂对汇总的放大为 $4.9\times$ 至 $29.7\times$ 、**逐格子最高** $47.9\times$, **倍数并非常数**, 更严重的是它会改变现象的形状(把“少数实例显著、其余与 0 不可区分”抹成“处处微小为正”)。因此本文主张改用由实例数据确定性推出的 **实例边界口径**, 并给出可复现的对照证据。其二, **组件有效性的重新判定**: 在实例边界口径下, 六个阶梯臂的逐级增量为 MIX3 初始化 $+3.406\%$ (10/10 实例胜出)、随机 VNS $+0.421\%$ 、精英档案 $+0.082\%$, 而 Q-PAS 仅 $+0.030\%$ ($p = 0.625$, 不显著)、RL 选算子 -0.003% ; 进一步用 anytime 轨迹证明算力在 $G = 200$ 附近已接近饱和, 因此 RL 组件的失效不是“学不到”, 而是**没有空间可学**。其三, **可事前判定的增益**: 我们提出一个零代探针——只调用一次初始种群构造(不做任何搜索), 用初始前沿 HV 的杠杆 λ_0 预测“某个新实例上 MWR 初始化相对论文口径是否真有净增益”, 并在 66 个 Hurink e-data 实例上做完全预注册的留出验证。

关键词: 柔性作业车间调度; 分解型多目标进化算法; 模糊加工时间; 强化学习; 消融实验; 评价口径; 可复现性

1 引言

双目标模糊柔性作业车间调度问题 (bi-objective fuzzy flexible job-shop scheduling problem, FFJSP) 要在不确定加工时间下同时最小化最大完工时间与机器总负载, 是典型的 NP 难组合优化问题。Li 等 [1] 提出的 RMOEA/D 把 Q-learning 同时接在两个决策点上: 一是每代选择 Tchebycheff 分解中的参数 T (Q-PAS), 二是选择变邻域搜索的算子 (RVNS), 并在 Brandimarte 基准上报告了相对基线的改进。

复现这类“学习型元启发式”时, 有两个容易出错、且出错方式很隐蔽的地方:

(1) **多目标指标的评价口径**。超体积 (HV) 需要把两个目标归一化到同一量纲。把归一化边界取为“参与比较的前沿的极值”(盒口径) 是一行代码就能写出的做法, 但它使边界成为一个**依赖于臂集与实例集**的量: 同一份数据, 只要换掉比较对象, HV 读数就变。这在复现里意味着一个组件“有没有效果”的结论会随同批实验的设计而漂移。

(2) **比较基准与问题的不对齐**。当要回答“该不该用我们提出的初始化”时，正确的对照是**论文自己的初始化**；而“随机初始化”只能回答“有个好起点值多少”。这两个量在同一批数据上都算得出来，但用前者去论证后者是无效的。

本文把这两点作为方法学主线，并在严格执行它们之后重新评估 RMOEA/D 的每个组件。结论是负面的：真正有效的只有初始化与算力总量，两个 RL 组件在本基准上没有可实现空间。但我们并不止步于负结果——我们进一步给出一个**零代探针**，它能以一次初始种群构造的代价事前判定“初始化的净增益在某个新实例上是否会出现”，并在一个 66 实例的独立留出集上验证。

贡献。

- 量化了盒口径的偏差：同一批数据、同一臂对，效应量被放大约一个数量级，且**放大倍数不是常数**（按臂对汇总 $4.9\times-29.7\times$ ，逐格子最高 $47.9\times$ ），显著性检验的 p 与胜出场数同样改变 (§3)。
- 在实例边界口径下重新给出六臂消融阶梯的逐级效应，并把“算力饱和”量化，由此把 RL 组件的失效解释为**动作空间与算力上都没有空间** (§5)。
- 提出零代探针门控： λ_0 （初始前沿 HV 杠杆）与净增益在开发集上完全分离；在 66 个 Hurink 实例的预注册留出集上给出无偏的命中/误放/漏放计数 (§6)，并回答“门控需要多少 seed” (§7)。
- 全部脚本、原始日志与“一个数字一个来源”的导出流程随文公开，论文中每个数字都由 `scripts/paper_export.py` 从 `logs/` 现场生成。

2 问题、算法与指标

2.1 双目标模糊 FJSP

给定 n 个工件、 m 台机器，每个工件的每道工序的加工时间用三角模糊数 $\tilde{t} = (t_1, t_2, t_3)$ 表示，且可在其可行机器集合中任选一台加工。目标是

$$\min F = (f_1 = C_{\max}, f_2 = W), \quad (1)$$

其中 $C_{\max}$ 为最大完工时间， W 为机器总负载。三角模糊数的比较与“模糊 $\rightarrow$ 确定” (crisp) 折算沿用 Li 等 [1] 的约定，以保证与本项目复现对象一致；模糊区间由实例名与随机种子共同决定，因此同一实例在不同 seed 下的模糊时间不同，这使“同 seed 配对”成为一切组间比较的基本单位。

2.2 超体积 (HV)

本文的单一汇总指标是前沿的 HV，参考点固定为 $\text{ref} = (1.02, 1.02)$ 。HV 的**归一化边界**取法有两种，本文的全部结论都建立在第二种之上 (§3)：

- **实例边界口径**（本文采用）：边界 (lo, hi) 由实例数据确定性推出（下界取临界路径下界、上界取全部工序最长时间之和），与**参与比较的臂集无关**。实现见 `instance_hv_bounds()`，算法落盘的 `final_hv` 用的就是它。

- **盒口径**（仅作对照）：边界取参与比较的**前沿的极值**，实现见 `estimate_hv_bounds()`。

2.3 RMOEA/D 的可插拔组件

复现中我们把算法拆成六个臂（表 2 的”阶梯”列），每一级相对上一级只打开一个组件： D_1 为纯 MOEA/D（固定 $T = 10$ ，关闭 MIX3/RVNS/Q-PAS/精英档案）； D_2 打开 MIX3 初始化； D_3 打开随机 VNS； D_4 把固定的 T 换成 Q-PAS； D_5 打开精英档案；RMOEAD 把随机 VNS 换成 RL 选算子。这一阶梯与文献 [1] 表 5 的步骤分解对齐，因而”每一级是否有效”就是对该文主张的逐条检验。RMOEAD 与 D_5 只差”谁选算子”，是检验 RL 组件**最干净的单变量对照**（等算力、同其它一切）。

3 评价口径：一个会改变结论的隐藏变量

3.1 盒口径的两个缺陷

(a) **跨实例污染**。若把多个实例的前沿并进同一个盒，边界会跨越相差一个数量级的实例（如 Mk07 的 HV 量级约 150/700、Mk10 约 300/2000），于是所有实例的值都被”拉”到相近区间，读出”所有变体都近乎完美”的假象。凡按（臂, seed）在多个实例上摊平再取极值的写法都会踩这一点。

(b) **臂集污染**。盒只应包含**参与比较的臂**。若把与本次比较无关的臂一并放进盒（例如把另做的一批 T 扫描臂混进消融实验的日志），上界被无关数据撑高，同一份数据的所有读数随之改变。本文的对照实验因此**逐臂对**重算边界，即盒内恰好只有被比较的两个臂。

3.2 量化的后果

表 2 右三列给出同一批数据（8 臂 $\times$ 10 实例 $\times$ 30 seeds）在两种口径下的读数。三点值得注意：

1. **放大倍数不是常数**：按臂对汇总（比值之比，§4.3）从 $4.9\times$ 到 $29.7\times$ 不等，逐格子最高达 $47.9\times$ （Mk10 的 $D_4|D_3$ ：实例边界 -0.017% $\rightarrow$ 盒口径 -0.829% ）。因此”盒口径数字除以固定倍数即可折回”是错的。图 1 把两种口径并排画出， $D_2|D_1$ 的相对增幅被放大 $5.9\times$ ，而几乎为零的 $D_4|D_3$ 被放大 $10.6\times$ ——**越接近零的效应，相对放大越厉害**：50 个（实例，臂对）格子里， $|\Delta HV| \leq 0.02\%$ （”接近零”的显式阈值）的 9 个格子放大中位数为 $16.7\times$ ，其余 41 个只有 $7.9\times$ 。**秩相关的口径必须写明**：对 $\log_{10}|\text{放大}|$ 取秩得 Spearman = -0.37 ($p = 0.009$)；若直接对原始放大倍数取秩则只有 -0.25 ($p = 0.076$ ，未过线)。两者方向一致、强弱不同——不写出取对数这一步，读者无法复核这个数。这正是本文主张的”**任何数字离开其口径不可引用**”的一个具体例子。
2. **p 值与胜出场数也会变**。这一点比幅度更容易被忽略：口径改变不只是”数字大小”，而是**显著性判定本身**。
3. **现象的形状会变**。本文 §5.3 会遇到一个”3/10 实例显著、7/10 与 0 不可区分”的双峰形态；在盒口径下，那 7 个非显著实例变成从 -0.58% 散到 $+0.95\%$ 的一团（中位 $+0.29\%$ ，且其

中 3 个翻转了符号)，于是被读成“效应弱但普遍存在”。形状的失真比幅度的失真更难察觉。

3.3 报数规则

本文后续一律遵守：效应量与显著性只报实例边界口径；对照展示盒口径时必须同时给出放大倍数；任何数字离开其口径不可引用；跨实例只比相对差与秩，不比 HV 绝对值（各实例边界不同）。

4 实验设置

4.1 实例集

表 1 列出实例。开发集为 Brandimarte Mk01–Mk10（论文原始基准），用于复现与门限标定；留出集为 Hurink e-data 的全部 66 个实例，用于留出验证。留出集的选择完全预注册：取该数据集的全部实例，不做任何按结果的挑选；实例文件取自公开基准库并以 SHA-256 记录来源（data/hurink/PROVENANCE.json）。

4.2 参数与算力

种群规模 $N_p = 100$ ，代数 $G = 200$ ，每个配置 30 个随机种子（42–71）， $\text{ref} = (1.02, 1.02)$ 。所有组间比较都做同 seed 配对，以消掉“模糊时间随 seed 变”带来的实例内噪声。响应面实验 (§5.2) 另在 $G = 2000$ 上限下按墙钟预算分档，用于观察“算力变大时效应如何变”。

4.3 统计口径

同一组比较给两套读数：**实例级**（先在实例内对 30 个 seed 取均值， $n = 10$ 或 $n = 66$ ）与 **run 级**（逐 seed 配对， $n = 300$ ）。检验用 Wilcoxon 符号秩，效应量用配对 Cohen’s d_z ；相对增幅定义为 $\overline{\Delta\text{HV}}/\overline{\text{HV}}_{\text{上一级}}$ （先求均值再作比，不用 $\overline{\Delta}/\overline{\text{HV}}$ ——后者在效应 ≈ 0 时会反号；**盒口径的放大倍数也用同一约定**： $\overline{\Delta\text{HV}}_{\text{盒}}/\overline{\Delta\text{HV}}_{\text{实例}}$ ，而不是逐 run 放大倍数的平均，两者相差可达数倍）。存在多个候选预测变量时，用**置换零假设**（固定预测变量的秩矩阵、只打乱实例与目标的对应）做家族错误率校正，而不是 Bonferroni：在 $n = 10$ 、8 个候选的设定下，纯噪声的 $\max|\rho|$ 的 95% 分位就有 0.81，Bonferroni 的 0.00625 门槛过松。

4.4 复现环境

代码为 Python 实现，数值依赖 NumPy/SciPy；实验按实例分批驱动并支持断点续跑。论文的每一个数字都由 scripts/paper_export.py 从结果文件现场生成，取不到即报错，不允许人工填数。




图 1: 六臂阶梯的逐级 ΔHV 相对增幅: 实例边界口径 (实心, 正文引用) 与盒口径 (斜纹, 仅作对照)。盒口径把接近零的效应相对放大得最多, 红色标注为放大倍数。

5 结果

5.1 组件阶梯: 只有初始化与随机 VNS 站得住

表 2 与图 1 给出六臂阶梯的逐级增量。在实例边界口径下: MIX3 初始化 +3.406% (10/10 实例胜出, $p = 0.002$)、随机 VNS +0.421% (10/10, $p = 0.002$)、精英档案 +0.082% (10/10, $p = 0.002$); 而 Q-PAS 只有 +0.030% (5/10, $p = 0.625$, 不显著), RL 选算子 -0.003% (6/10, 不显著)。注意最后一行的含义: RMOEAD 与 D_5 的唯一差别是“用 RL 选算子”还是“随机选算子”, 等算力、同其它一切——把 RL 组件换成随机选择, 结果没有区别。

5.2 算力-算法响应面: 不是学不到, 是没空间可学

图 2 把每个臂对放在同一族“墙钟预算分数” (10%, 25%, 50%, 75%, 100%, G 上限 2000) 上比较。初始化的效应随算力增加而显著衰减: 在 10% 预算处三个实例的 $|\Delta HV|$ 为 0.024/0.064/0.091, 到全额预算时只剩 0.0010/0.0028/0.0085 (衰减 10.7–23.8 倍); 而 RL 选算子在所有预算档上都贴着零线。表 3 给出全额预算下的绝对值: 非初始化组件的最大者也只有 1.1×10^{-3} (Mk09 的 RL 选算子)。

5.3 同一批数据上的两个目标量

MWR 是我们的一个派工式工序初始化变体 (按剩余工时规则决定工序顺序, 只在 MA 维度保留原算法的随机性)。要问“该不该用它”, 必须把对照设成 **论文自己的 MIX3 初始化** (目标 B); 把它对照随机初始化 (目标 A) 回答的是另一个问题。表 4 与图 3 同时给出两者。

- **目标 A** (I_{mwr} vs. I_{rand}): 10/10 实例为正、**8 个显著** (只有 Mk01 与 Mk05 不显著), 幅度 +0.05% 至 +8.69%。这说明“有个好起点”普遍有价值。
- **目标 B** (I_{mwr} vs. I_{mix3} , 净增量): **只有 3/10 显著**, 幅度 +0.54% 至 +0.73%; **其余 7 个与 0 不可区分** (-0.22% 至 +0.02%, 全部不显著)。




图 2: 算力-算法响应面。(a) 原始 ΔHV 随墙钟预算的衰减；(b) 标准化效应 d_z 。初始化（红）是唯一随算力增加而衰减的显著效应，RL 选算子（绿）全程贴零。




图 3: 两个目标量的逐实例比较。目标 A（蓝）处处为正；目标 B（红）只在 Mk06/Mk08/Mk10 上显著为正，其余七个与 0 不可区分。

因此 MWR 的净增量是**全有或全无**的：它在少数实例上有值，在其余实例上一分不赚。把目标 A 的读数当作目标 B 的答案，正是本文要提醒的第二类错位；它会把”Mk10 上有净增益”错误地推广为”该初始化普遍更好”。

5.4 零代探针：把事后解释升级为事前判据

既然净增益是”全有或全无”，一个自然的问题是：**能不能事前知道某个实例属于哪一类？**最直接的判别量是”初始化的 makespan/HV 杠杆”，但它通常是事后量（从末代档案算）。我们提出的探针只调用一次初始种群构造（等价于 $G = 0$ ，一次搜索都不做），取两个变体初始前沿 HV 的比值：

$$\lambda_0 = \frac{\overline{HV}_0(I_{\text{mwr}}) - \overline{HV}_0(I_{\text{mix3}})}{\overline{HV}_0(I_{\text{mix3}})} \times 100\%, \quad (2)$$

其中 $\overline{HV}_0$ 为 30 个 seed 的初始前沿 HV 均值（实例边界口径、ref 同正式实验）。代价是每实例 $\times 30$ seeds 约 1.4s。

在开发集（Mk01–Mk10）上，净增益为正的 3 个实例的 λ_0 都落在 $[-0.53\%, +0.64\%]$ 内，其余七个都低于门限 -1.0% （最接近的 Mk09 为 -1.06% ）；取门限 $\lambda_0 \geq -1.0\%$ 即 **完全分离**：3/3 命中、0 误放、0 漏放。该门限在开发集上标定后**冻结**，不再按留出集调整。

这里必须把两个相关系数**分开报**，否则会重犯本文所批评的那类错位： λ_0 自身 $\rho = +0.77$ （名义 $p = 0.009$ ）；若改取 9 个事前候选的家族最大，最高者并不是 λ_0 而是”初始种群**平均** makespan 杠杆”， $\rho = +0.83$ 、置换校正 $p = 0.035$ 。注意家族零假设下 $\max |\rho|$ 的 95% 分位为 0.81，即 λ_0 **自身过不了这道家族校正**（ $+0.77 < 0.81$ ）。因此我们不以 ρ 的显著性作为门控依据，只以下面的门限分类结果为准；这也正是必须做独立留出验证的原因。

需要强调的是，事后量”最终 makespan 杠杆”与净增益的相关更高（ $\rho = +0.95$ ），但**用它做门控是循环论证**：要算它必须先把两个臂都跑完。探针的价值恰恰在于代价只有一次初始种群构造。

6 独立留出验证：Hurink e-data 的 66 个实例

（留出验证数据尚未生成：本节数字块、表格与图将在 `hurink_aig.json` 就绪后由导出器自动填充。）

为什么还需要一个独立留出集：开发集只有 $n = 10$ ，§5.3 ”3 个显著、7 个与 0 不可区分”这个形态本身就建立在这点样本上，而门限又是从同一批实例上挑出来的，因此开发集上的”完全分离”不能作为证据。我们把门限 $\lambda_0 \geq -1.0\%$ 原样搬到留出集——实例是 Hurink e-data 的 **全部 0 个**，不做任何按结果的挑选；每个实例跑 I_{mwr} 与 I_{mix3} 两个臂、每臂 30 个种子，参数与算力与开发集完全一致。

（留出验证数据尚未生成。）

表 5 给出两个集合上的混淆矩阵，表 6 逐实例列出探针 λ_0 与目标 B 的净增量。留出集的 λ_0 取值范围是 $[0\%, 0\%]$ ，而开发集正例的 λ_0 落在 $[-0.53\%, +0.64\%]$ ——两个集合的 λ_0 分布并不同构，这正是”门限在开发集上冻结、再到留出集检验”要暴露的东西：门控可靠与否，取决于留出集的 λ_0 有多少落在门限的决策边界附近。

7 门控需要几个 seed？

零代探针虽然便宜，但它仍需要 30 个 seed。开发集上两类实例的 λ_0 只相隔约 0.5 个百分点（正例最低 -0.53% ，非正例最高 -1.06% ），因此”少采几个 seed 会不会翻掉判定”必须实测，否则”廉价门控”的说法是不成立的。

做法是：对每个实例先算出 30 个 seed 的逐 seed 值，再对 $n \in \{1, 2, 3, 4\}$ 枚举全部 $\binom{30}{n}$ 个子集、对更大的 n 随机抽样 2000 个子集，用与正式探针**完全相同的估计量**重算 λ_0 ，最后看判定是否与该实例 30-seed 判定一致。表 7 给出结果。

结论是分层的：**离门限远的实例在 $n = 1$ 就已经稳定**，而**贴着门限的实例（如 Mk09， $\lambda_0 = -1.06\%$ ，只比门限低 0.06 个百分点）即使到 $n = 10$ 也只有 0.73 的一致率**。跨实例平均一致率在 $n = 1$ 时约 0.95，看起来很好，但最差实例只有 0.50——这个平均值把两类实例混在一起，掩




图 4: 零代门控在开发集 (圆) 与留出集 (三角) 上的分离情况。门限 $\lambda_0 = -1.0\%$ 在开发集上标定后冻结。

盖了边界实例的不稳定。因此正确的用法是：除了门限判定，还要看到**门限的距离**；距离小于约 0.62 个百分点的实例应被标为”不确定”，或加大 seed 预算后再判。

8 讨论

8.1 为什么两个 RL 组件没有空间

三条证据互相独立且一致：(1) 阶梯上 Q-PAS 与 RL 选算子均不显著；(2) 对 T 的动作空间做穷举式扫描，空间内最优与最差的差只有 $+0.31\%$ ($p = 0.78$)，说明**动作空间本身的天花板就很低**；(3) 算力响应面显示 $G = 200$ 附近已接近饱和，把预算放大到 $G = 2000$ 也只带来 1.5% 量级的绝对值。把三者放在一起，RL 组件失效的解释不是”学习算法不行”，而是**它在两个方向上都无事可做**：可选的 T 值彼此差不多，而多算一点也没有回报。反之，初始化改变的是搜索的**起点**，它的效应不随算力增长而被稀释（图 2 的衰减正是”起点优势被后续搜索逐步追平”），因此这里是这里唯一稳健的杠杆。

8.2 口径问题在复现研究中的普遍性

”取参与比较的前沿极值”作为归一化边界，在文献与开源实现里都很常见，它的问题不是”不精确”而是**不可比**：读数依赖于同批实验的设计。本文的量化结果是，同一批数据下效应量被放大 $4.9\times$ 至 $29.7\times$ （逐格子最高 $47.9\times$ ，由 `caliber_audit.py` 与 `paper_export.py` 两条独立路径算出同一组数），且倍数不是常数；显著性判定与胜出场数也会变。更值得警惕的是它改变现象的形状——把”少数实例显著、其余与 0 不可区分”抹成”处处微正”，后者恰好支持”效应弱但普遍”这个错误结论。我们建议复现研究把口径写成一条**可执行的纪律**（本文 §3），并在论文里同时给出对照，让读者能自行折算。

8.3 对”组件有效性”这类结论的建议

本文的负面结论并不是”这个算法不好”，而是指出**在这批基准与这个算力预算下**，两个学习组件没有可实现空间。要让”某学习组件有效”成为可靠主张，至少需要：与要回答的问题对齐的

对照（目标 B 而非 A）、等算力的比较、效应量与显著性两套读数、以及在未参与任何调参的实例上复现。本文的 Mk06 与 Mk08 属于后一类：它们从未参与初始化变体的调参，却复现了 Mk10 上的净增益方向，这比”在调参实例上更好”可信得多。

8.4 局限

- 留出集只有 Hurink *e*-data 一个族；不同族（如 *r/v*-data）的弹性比更低，探针的判别力是否保持未测。
- 门限 $\lambda_0 \geq -1.0\%$ 是在 $n = 10$ 的开发集上挑出的，虽然留出集验证无偏，但门限值本身没有跨族校准；§7 已给出边界实例的不稳定性，实际使用时应把”距门限的距离”一并报告。
- 本文只报告 HV 单一指标；虽然 HV 是双目标问题的常用汇总，但不排除某些组件在特定目标方向上有局部作用。
- 响应面实验受墙钟预算上限限制（ $G \leq 2000$ ），”饱和”的结论限定在该范围内。

9 结论

我们在统一、可复现的评价口径下重新审计了 RMOEA/D 的各组件。主要结论是：在本基准与算力预算下，真正有效的是**初始化与算力总量**（且后者很快饱和），两个 RL 组件（Q-PAS 选 *T*、RVNS 选算子）没有可实现空间；同时我们发现并量化了一个被普遍忽视的评价口径问题——归一化边界的取法会把效应量放大一个数量级、改变显著性判定、甚至改变现象的形状。作为建设性的部分，我们给出一个零代探针，用一次初始种群构造的代价事前判定”某新实例上初始化的净增益是否会出现”，并在 66 个独立实例上做了预注册的留出验证，同时诚实地给出它在门限附近的稳定性边界。

我们希望本文的方法学部分——口径纪律、目标量对齐、置换零假设、以及”把结论放到未调参实例上”——对同类复现工作有直接的可操作性。

参考文献

- [1] J. Li, et al. A reinforcement learning based RMOEA/D for bi-objective fuzzy flexible job shop scheduling. *Expert Systems with Applications*, 203:117380, 2022.
- [2] K. Deb, et al. A fast and elitist multiobjective genetic algorithm: NSGA-II. *IEEE TEC*, 6(2):182–197, 2002.
- [3] Q. Zhang, H. Li. MOEA/D: A multiobjective evolutionary algorithm based on decomposition. *IEEE TEC*, 11(6):712–731, 2007.
- [4] P. Brandimarte. Routing and scheduling in a flexible job shop by tabu search. *Annals of Operations Research*, 41(3):157–183, 1993.
- [5] E. Hurink, B. Jurisch, M. Thole. Tabu search for the job-shop scheduling problem with multi-purpose machines. *OR Spektrum*, 15(4):205–215, 1994.

表 1: 实例集特征

(a) <i>Brandimarte Mk01–Mk10</i> : 复现与消融的开发集					
实例	工件	机器	工序	弹性比	c_v
Mk01	10	6	55	2.09	0.56
Mk02	10	6	58	4.10	0.50
Mk03	15	8	150	3.01	0.63
Mk04	15	8	90	1.91	0.63
Mk05	15	4	106	1.71	0.32
Mk06	10	10	150	3.27	0.63
Mk07	20	5	100	2.83	0.64
Mk08	20	10	225	1.43	0.48
Mk09	20	10	240	2.52	0.43
Mk10	20	15	240	2.98	0.47
(b) <i>Hurink e-data</i> : 66 个实例, 全部用作 独立留出集 (不挑选)					
×1	6	6	36	1.17	—
×1	7	7	49	1.18	—
×3	10	5	50	1.20	—
×2	10	5	50	1.18	—
×1	13	4	52	1.21	—
×1	11	5	55	1.20	—
×1	14	4	56	1.20	—
×1	12	5	60	1.18	—
×1	10	6	60	1.17	—
×1	8	8	64	1.17	—
×1	8	9	72	1.17	—
×4	15	5	75	1.15	—
×1	15	5	75	1.16	—
×1	10	10	99	1.13	—
×8	10	10	100	1.13	—
×4	20	5	100	1.13	—
×2	20	5	100	1.14	—
×9	10	10	100	1.14	—
×2	15	10	150	1.15	—
×1	15	10	150	1.14	—
×2	15	10	150	1.16	—
×4	20	10	200	1.14	—
×1	20	10	200	1.13	—
×3	15	15	225	1.15	—
×2	15	15	225	1.14	—
×2	30	10	300	1.14	—
×3	30	10	300	1.13	—
×2	20	15	300	1.13	—
×1	20	15	300	1.13	—

弹性比 = 每道工序可选机器数的均值; c_v = 模糊三角加工时间的变异系数。Mk01–Mk10 用于复现、消融与**门限标**

表 2: 组件阶梯的逐级增量: 实例边界口径 (正文引用) 与盒口径 (仅作对照)

实例边界口径						盒口径	
阶梯	组件	ΔHV 相对增幅 (%)	实例胜出	d_z	p	相对增幅 (%)	放大
D2 D1	MIX3 初始化	+3.406	10/10	+0.98	$2.0 \times 10^{-3**}$	+19.956	5.9×
D3 D2	随机 VNS	+0.421	10/10	+0.61	$2.0 \times 10^{-3**}$	+4.199	10.0×
D4 D3	Q-PAS	+0.030	5/10	+0.05	0.625	+0.314	10.6×
D5 D4	精英档案	+0.082	10/10	+0.65	$2.0 \times 10^{-3**}$	+0.400	4.9×
RMOEAD D5	RL 选算子	-0.003	6/10	-0.01	0.625	-0.091	29.7×

Mk01–Mk10, 每格 $n = 30$ seeds 同 seed 配对。 ΔHV 相对增幅为**逐实例** $\overline{\Delta\text{HV}}/\overline{\text{HV}}_{\text{上一级}}$ 的跨实例均值 (不用 Δ/HV : 效应 ≈ 0 时会反号)。 d_z 为 run 级池化配对效应量 ($n = 300$), p 为实例级 Wilcoxon ($n = 10$)。 盒口径一列是**同一批数据**换口径重算的结果, 用来量化口径的影响; 正文的效应量一律取实例边界口径。

表 3: 算力全部花完时 (100% 预算) 各组件相对上一级的 ΔHV 绝对值

臂对	组件	Mk07	Mk09	Mk10
D2 D1	MIX3 初始化	+0.001	+0.003	+0.009
RMOEAD D5	RL 选算子	+0.000	-0.001	-0.000

每列一个实例; 预算按**墙钟** (anytime 轨迹) 分五分位 (10/25/50/75/100%, G 上限 2000)。 把算力加到上限以后, 除初始化以外的组件增量都不超过 1.1×10^{-3} (最大者为 Mk09 的 RL 选算子, 绝对值)。

表 4: 同一批数据、两个目标量: 目标 A (I_{mwr} vs. I_{rand}) 与目标 B (I_{mwr} vs. I_{mix3})

目标 A: 有好起点值多少					目标 B: MWR 相对论文口径的净增量		
实例	$\Delta\text{HV}(\%)$	胜出	d_z	p	$\Delta\text{HV}(\%)$	胜出	p
Mk01	+0.047	13/30	+0.06	0.685	-0.073	15/30	0.626
Mk02	+0.525	22/30	+0.74	$5.5 \times 10^{-4***}$	+0.010	17/30	0.556
Mk03	+3.879	30/30	+3.88	$< 10^{-4***}$	+0.023	17/30	0.328
Mk04	+0.467	21/30	+0.52	0.013*	-0.224	12/30	0.171
Mk05	+0.238	16/30	+0.24	0.184	+0.024	15/30	1.000
Mk06	+4.871	30/30	+5.76	$< 10^{-4***}$	+0.730	29/30	$< 10^{-4***}$
Mk07	+1.593	30/30	+3.25	$< 10^{-4***}$	-0.009	16/30	1.000
Mk08	+0.944	29/30	+1.55	$< 10^{-4***}$	+0.542	28/30	$< 10^{-4***}$
Mk09	+6.584	30/30	+5.88	$< 10^{-4***}$	+0.012	18/30	0.685
Mk10	+8.692	30/30	+8.25	$< 10^{-4***}$	+0.690	29/30	$< 10^{-4***}$

$n = 30$ seeds, 同 seed 配对; ΔHV 为实例边界口径的相对增幅。 目标 A 上 10/10 为正 (“好起点” 这一级确有普遍收益), 但**目标 B 只有 3/10 显著、其余 7 个与 0 不可区分** (配对 Wilcoxon $p \geq 0.17$; 注意 ΔHV 并非精确的 0, 非显著实例中仍为正的最大者是 +0.024%, 故 “有增益” 必须按显著性而非非零来判): MWR 的净增量是全有或全无, 并非 “普遍成立但幅度较小”。 拿 A 的结论回答 B 的问题即为目标量错位 (缺陷 26)。

表 5: 零代门控的混淆矩阵

留出验证数据尚未生成

本表为占位: logs/hurink_aig.json 未就绪。 生成后由 scripts/paper_export.py 覆盖。

表 6: 独立留出集 (Hurink *e*-data)

留出验证数据尚未生成

本表为占位: `logs/hurink_aig.json` 未就绪。生成后由 `scripts/paper_export.py` 覆盖。

表 7: 零代探针在不同 seed 预算下的稳定性 (Mk01–Mk10)

实例	$\lambda_0(30)$	λ_0 的子集标准差				与 30-seed 判定的一致率			
		$n=1$	$n=3$	$n=5$	$n=10$	$n=1$	$n=3$	$n=5$	$n=10$
Mk01	-7.22	1.34	0.74	0.56	0.35	1.00	1.00	1.00	1.00
Mk02	-2.45	0.63	0.35	0.26	0.16	1.00	1.00	1.00	1.00
Mk03	-4.03	0.27	0.15	0.11	0.07	1.00	1.00	1.00	1.00
Mk04	-5.94	1.19	0.65	0.48	0.31	1.00	1.00	1.00	1.00
Mk05	-3.68	0.85	0.47	0.35	0.22	1.00	1.00	1.00	1.00
Mk06	-0.39	0.33	0.18	0.13	0.08	1.00	1.00	1.00	1.00
Mk07	-2.57	0.42	0.23	0.17	0.11	1.00	1.00	1.00	1.00
Mk08	+0.64	0.48	0.26	0.20	0.13	1.00	1.00	1.00	1.00
Mk09	-1.06	0.36	0.19	0.14	0.09	0.50	0.60	0.65	0.73
Mk10	-0.53	0.32	0.17	0.13	0.08	0.97	1.00	1.00	1.00
跨实例均值	—	0.618	0.339	0.254	0.159	0.947	0.960	0.965	0.973

对每个实例枚举/抽样 n 个 seed 的子集, 用与正式探针完全相同的估计量 (先对 seed 求均值再作比) 重算 λ_0 , 再看判定是否与 30-seed 一致。门限 -1.0% ; 子集数见 `logs/probe_seed_var.json`。